

N421

* 벡터화 (vectorize)

: 텍스트를 컴퓨터가
계산할 수 있도록!

①

등장횟수 기반 : Bag-of-words
(TF, TF-IDF)

②

분포 기반 : word2vec (cbow, skip gram)
Glove
fastText

① 등장횟수 기반 단어 표현

- 말풍선에 존재하는 단어의 종류 = feature (차원)

차원(단어)을 줄여야 하는 이유? 차원의 저주

• Bag-of-words (Bow)

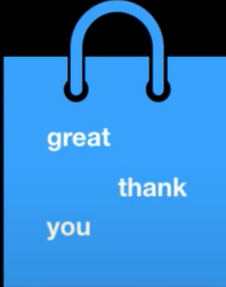
1) TF (Term Frequency)

- 불변, 단어순서 무시 only 단어 빈도

- CountVectorizer 사용

| awesome | thank | you | great | not | bad | good |
|---------|-------|-----|-------|-----|-----|------|
| 0 | 1 | 1 | 1 | 0 | 0 | 0 |

[0, 1, 1, 1, 0, 0, 0]



• awesome thank you [1, 1, 1, 0, 0, 0, 0]

x x x x x x x

• great thank you [0, 1, 1, 1, 0, 0, 0]

1+1 = 2 유사도 2

2) TF-IDF

- 특정 문서에만 등장하는 단어에 대해 가중치

수식: $TF-IDF(w) = TF(w) \times IDF(w)$

특정 문서내 단어 "수"

- TfidfVectorizer 사용

$\log\left(\frac{\text{분류대상 문서수}}{w \text{가 들어있는 문서수}}\right)$

$\log\left(\frac{n}{1+df(w)}\right)$

| | corpus | document | frequency | idf | information | number |
|---|----------|----------|-----------|----------|-------------|----------|
| 0 | 0.239165 | 0.478329 | 0.583318 | 0.173029 | 0.239165 | 0.000000 |
| 1 | 0.000000 | 0.000000 | 0.000000 | 0.000000 | 0.426900 | 0.000000 |
| 2 | 0.277399 | 0.277399 | 0.000000 | 0.200691 | 0.000000 | 0.67657 |
| 3 | 0.000000 | 0.000000 | 0.000000 | 0.000000 | 0.000000 | 0.000000 |
| 4 | 0.000000 | 0.000000 | 0.000000 | 0.414476 | 0.000000 | 0.000000 |
| 5 | 0.000000 | 0.000000 | 0.000000 | 0.384849 | 0.000000 | 0.000000 |

→ 실수의 형태로
결과가 나옴.
(DTM)

* 토큰화

I / am / a / student

토큰 4개 (단어 4개라고 볼 수 있다)

- 토큰화를 해야 벡터화를 할 수 있다
- Spacy Tokenizer
- 불용어 제거, 통사적 프레이밍
- 어간 추출 (Stemming), 품사어 추출 (Lemmatization)


* DTM (문서 - 단어 행렬)

벡터화된 문서를 문서 - 단어 행렬 형태로 나타냄.

| | Word_1 | Word_2 | Word_3 | Word_4 | Word_5 | Word_6 | → 단어 (컬럼) |
|--------|--------|--------|--------|--------|--------|--------|-----------|
| Docu_1 | 1 | 2 | 0 | 1 | 0 | 0 | |
| Docu_2 | 0 | 0 | 0 | 1 | 1 | 1 | |
| Docu_3 | 1 | 0 | 0 | 1 | 0 | 1 | |

One Hot Encoding doesn't have **similarity**

cosine similarity also 0 since angle is 90 degree



| unique word | encoding |
|-------------|-----------|
| thank | [1, 0, 0] |
| you | [0, 1, 0] |
| love | [0, 0, 1] |